

Jogi platform szakdolgozat témavázlat véleményezése

<https://gemini.google.com/app/5f2a0e487010b9d7>

User prompt: Köszönöm, megkaptam és átnéztem a témavázlatot. Az ügyvédkereső és jogi ügyfél-előszűrő platform jó, aktuális és szakdolgozati szempontból is erős téma lehet. Külön jó, hogy valós felhasználói problémából indulsz ki, értelmes MI-képességet tervezel a termékbe, és már a működés mérésére is gondoltál. A témát szívesen vállalom, de a jelenlegi tervet mindenképpen szűkítenünk kell. Most egyszerre szerepel benne dokumentum-OCR, LLM-alapú információkinyerés, ügytípus-besorolás, többféle ajánlórendszer, szintetikus adatgenerálás, agentic fejlesztési kísérlet, MI-alapú CI/CD-ellenőrzés, mikroszolgáltatásos architektúra és WebRTC-videóhívás. Ezek együtt több külön szakdolgozatnyi feladatot jelentenek. Fennállna a veszélye, hogy sok rész elkészül, de egyik sem lesz elegendően mélyen kidolgozva és értékelve. A dolgozat központi témáját így fogalmaznám meg: „MI-támogatott jogi ügyfél-előszűrő és ügyvéd-ajánló webalkalmazás tervezése, megvalósítása és értékelése.” A rendszer feladata ne jogi tanácsadás vagy a dokumentum végleges jogi értelmezése legyen. A termékhatár legyen világos: strukturáltan felveszi a felhasználó problémáját, egy korlátozott taxonómia szerint előzetes ügytípust javasol, majd magyarázható módon három megfelelő ügyvédprofilat ajánl. Alacsony bizonyosságnál kérdezzen vissza, vagy mondja ki, hogy nem tud felelősen besorolást adni. Az alábbi fokozatos MVP-sorozatot javaslom. MVP-0 – mérési és domainalap válassz 6–8 pontosan definiált jogterületet vagy ügytípust; készíts ügyvédprofil-sémát: szakterület, helyszín, nyelv, online vagy személyes konzultáció, elérhetőség, díjmodell; állíts össze 100–200 címkézett, anonimizált vagy szakmailag ellenőrzött szintetikus ügyleírást; készíts egyszerű szabályalapú besorolási és ajánlási baseline-t; előre rögzítsd a mérőszámokat és a tesztadatokat. MVP-1 – működő termékmag a felhasználó szövegesen leírja a problémáját; a rendszer strukturált kérdésekkel bekéri a hiányzó adatokat; ügytípust javasol bizalmi értékkel; tartalomalapú pontozással három ügyvédprofilat ajánl; az ajánlások mellett megmutatja azok indokait; legyen egyszerű adminfelület a kategóriák és profilok kezelésére. MVP-2 – dokumentumfeldolgozás először a PDF-ben már meglévő szöveget nyerd ki, OCR csak a szkennelt vagy képalapú iratoknál szükséges; legyen személyesadat-felismerés és -maszkolás; a rendszer strukturált mezőket nyerjen ki, és mutassa meg, melyik oldal vagy szövegrész alapján tette ezt; alacsony megbízhatóságú adatnál kérjen felhasználói megerősítést; valós jogi iratok helyett először anonimizált vagy szintetikus tesztanyaggal dolgozz. MVP-3 – összehasonlítás és validáció hasonlíts össze egy szabályalapú baseline-t, egy embeddings vagy szemantikus módszert és egy LLM-alapú besorolást; ne csak pontosságot mérd, hanem válaszdőt, költséget, hibamintákat és azt is, milyen gyakran kell a rendszernek tartózkodnia a választól; az ajánlásnál mérd top-3 relevanciát, szakértői vagy előre címkézett referencia alapján; végezz kisebb felhasználói tesztet arra, hogy érthető-e az előszűrés és az ajánlások indoklása. Az ajánlórendszerrel nem collaborative filteringgel vagy mátrixfaktorizációval indulnék. Kezdetben nem lesz elegendő valós felhasználó-ügyvéd interakció, a szintetikus visszajelzés pedig nem bizonyít valós ajánlási minőséget. Első megoldásként tartalomalapú, több szempontos rangsorolás legyen, amely figyelembe veszi az ügytípust, helyszínt, nyelvet, elérhetőséget és a konzultáció formáját. Erre később épülhet szemantikus hasonlóság vagy tanulható rangsorolás. A méréshez érdemes előre rögzíteni: ügytípus-besorolás: macro-F1 és osztályonkénti recall; információkinyerés: mezőszintű precision, recall és F1; OCR: karakter- vagy szóhibaarány; ajánlás: Precision@3, MRR vagy nDCG@3; üzemeltetés: válaszdő, költség lekérdezésenként és hibaarány; felhasználói oldal: feladatvégzési arány, idő és az ajánlások érthetősége. Az architektúrát sem érdemes előre mikroszolgáltatásokra bontani csak azért, hogy mikroszolgáltatásos legyen. Az első iterációban jobb egy tisztán modularizált alkalmazás, külön ügyfél-intake, dokumentumfeldolgozó, besoroló és ajánló, LLM-gateway, valamint audit- és mérési modullal. Akkor emeld ki külön szolgáltatást, ha arra konkrét indok van, például eltérő skálázás, hosszú háttérfeldolgozás vagy erősebb adatbiztonsági izoláció. A fejlesztési folyamat MI-támogatása jó kiegészítő vizsgálati irány, de ne legyen a termék mellett egy második teljes kutatás. Egy jól körülhatárolt modulnál összehasonlíthatod az autonóm agentic és a felügyelt

MI-támogatott munkafolyamatot azonos követelmények mellett. Mérheted a fejlesztési időt, az emberi beavatkozások számát, a teszteredményeket, a hibákat és az utólagos javítási időt. Ehhez kezdettől vezess MI-használati naplót. A WebRTC-videóhívást most kivenném a vállalt szakdolgozati szkópból. Hasznos későbbi termékfunkció lehet, de nem segít megválaszolni a fő kutatási kérdést, miközben sok integrációs munkát vinne el. A piackutatásban legalább az alábbi megoldásokat érdemes összehasonlítani: a Magyar Ügyvédi Kamara Országos Ügyvédkeresője; néhány piaci ügyvédkereső portál; az Ügyvédbróker ügybeküldési és ajánlatkérési modellje; egy legaltech megoldás, például az Alex. Ne csak funkciólistát készíts: vizsgáld a profiladatok hitelességét, a keresés és ajánlás módját, a dokumentumfeltöltést, időpontfoglalást, adatvédelmet, magyarázhatóságot és az üzleti modellt is. A saját rendszer megkülönböztető értéke ne pusztán az legyen, hogy „MI-t használ”, hanem az, hogy ellenőrizhető előszűrést, bizonytalanságkezelést és magyarázható ajánlást ad. Kiemelten fontos a felelős működés. A feltöltött jogi iratok érzékeny személyes adatokat tartalmazhatnak, és az MI téves besorolása valós kárt okozhat. A dolgozat egyik szakmai értéke éppen az lehet, hogy bemutadod a bizonytalanság kezelését, az emberi megerősítést, a forráshelyek visszamutatását, az adatminimalizálást és azt, hogy a rendszer nem helyettesíti az ügyvédi tanácsadást. Következő lépésként kérlek hozz létre egy megosztott GitHub- vagy GitLab-repository-t. Ha a repository privát, a bilickiv@gmail.com címmel oszd meg. Első körben kerüljön bele: README a problémával, célcsoporttal és termékhatárral; egyoldalas MVP-leírás és priorizált backlog; piackutató összehasonlító táblázat; jogterületi taxonómia és címkézési szabályok; use case- és pageflow-vázlat; első adatmodell és architektúraábra; mérési és validációs terv; adatvédelmi, jogi, MI- és biztonsági kockázati lista; MI-használati napló. Ha az induló repository és az MVP-0 első anyagai elkészültek, elég egy rövid emailt küldened a linkkel, és szívesen átnézem, véleményezem, illetve segítek a következő iteráció pontosításában. Összefoglalva: a témát jó választásnak tartom és szívesen vállalom, de a siker kulcsa a szűk, mérhető termékmag, a magyarázható ajánlás, a felelős adatkezelés és az, hogy a rendszer képességeit ne csak bemutasd, hanem előre rögzített módszertannal értékeld is. List all the features this project will have

Response: Based on the provided project outline, the AI-supported legal client pre-screening and lawyer recommendation web application will have the following features:

User Intake & Interaction

- **Text-based problem submission:** Users can describe their legal problem in their own words.
- **Dynamic Q&A:** The system asks structured follow-up questions to gather missing information based on the initial input.
- **Low-confidence fallback:** If the system is uncertain about a classification, it prompts the user for clarification or explicitly states it cannot confidently categorize the issue.
- **Disclaimer display:** Clear product boundaries stating the system provides preliminary screening, not definitive legal advice or interpretation.

Document Processing

- **PDF text extraction:** Native text extraction from digital PDFs.
- **Conditional OCR:** Optical Character Recognition specifically triggered for scanned or image-based documents.
- **PII detection & masking:** Automatic identification and anonymization of sensitive personal data within uploaded documents.

- **Traceable data extraction:** Structured field extraction that shows the user exactly which page or text snippet the information was pulled from.
- **Human-in-the-loop verification:** Prompts requiring user confirmation when document extraction yields low-reliability data.

AI Classification & Recommendation Engine

- **Case-type classification:** Categorizes the user's issue into a predefined taxonomy of 6–8 specific legal areas, accompanied by a confidence score.
- **Multi-criteria content-based recommendation:** Suggests exactly three relevant lawyer profiles based on matching criteria (specialty, location, language, consultation format, availability, and fee model).
- **Explainable AI (XAI):** Displays the specific reasons and matching logic behind why those top three lawyer profiles were recommended.

Administration & Management

- **Admin interface:** A dashboard to manage lawyer profiles and the legal category taxonomy.
- **Lawyer profile schema:** Structured profiles containing specific data points (expertise, location, languages spoken, online/in-person availability, pricing model).

Architecture & Auditing

- **Modular architecture:** Distinct modules for client intake, document processing, classification/recommendation, LLM gateway, and auditing.
- **Audit and measurement module:** Built-in tracking for system performance, including classification accuracy, response times, API costs, error patterns, and task completion rates.
- **AI usage logging:** A tracked log of AI usage during the development process to compare AI-supported workflows against standard development.

Explicitly Excluded Features (Out of Scope)

- WebRTC video calling capabilities.
 - Collaborative filtering or matrix factorization for recommendations.
 - A strict microservices architecture (favoring a modular monolith instead).
 - Provision of binding legal advice.
-